

Universidad Nacional Autónoma de Honduras
Facultad de Física
Departamento de Gravitación, altas energías y
radiaciones



**Análisis de la enfermedad de Alzheimer mediante
señales electroencefalográficas**

Alumno:
Diego Amador 20181000106

Seminario de investigación Fs-700

Sección: 1700

Docente: Angel Velasquez

Tegucigalpa, M.D.C., 8 de Diciembre de 2023

Tabla de contenidos

| | Página |
|---|-----------|
| A. Indice de abreviaturas | 3 |
| B. Resumen | 4 |
| C. Introducción | 5 |
| D. Objetivos | 6 |
| 1. Objetivo general | 6 |
| 2. Objetivos particulares | 6 |
| E. Generación de EEG | 7 |
| 1. Lóbulos del cerebro | 7 |
| 2. Señales de EEG | 7 |
| 3. Visualización de un EEG | 8 |
| F. Espectro de potencia | 10 |
| 1. Canales | 11 |
| 2. Cluster | 15 |
| 3. ICA | 15 |
| G. Análisis estadístico | 16 |
| 1. Entropía espectral | 16 |
| 2. Coeficiente de correlación de Pearson | 17 |
| 3. Residuales | 17 |
| 4. Gráfico Q-Q | 19 |
| 5. Linealización del cluster | 20 |
| 6. Distribución Gaussiana e Histogramas | 22 |
| H. Conclusión | 24 |
| I. Referencias | 25 |

A. Índice de abreviaturas

EEG: Electroencefalograma

EA: Enfermedad de Alzheimer

MMSE: Mini Examen de Estado Mental (Mini – Mental Score Examination)

DCL: deterioro cognitivo leve

PSD: Espectro de densidades

APS: Activity power spectrum

ICA: Análisis de componentes independientes

Q-Q: cuantil-cuantil

B. Resumen

La EA es una enfermedad neurodegenerativa que provoca perdida gradual de memoria cada vez más notoria, se ha convertido en una de las enfermedades crónicas que más afectan a la población, sobre todo en el caso de adultos mayores.

Las señales encefalográficas muestran la actividad cerebral, la cual es analizada para conocer condiciones específicos de su funcionalidad o trastornos mentales.

El fin principal de este estudio es hacer uso de las señales de EEG y PSD de por medio de un programa de MATLAB para poder visualizar las señales y la actividad, y poder llegar a observar un comportamiento en la EA y con ello facilitar su diagnóstico.

Los sets de datos de los EEG de los pacientes, tanto los de cerebro sano y para los de EA, fueron obtenidos de un ser de datos de "openNeuro" de la universidad de Ioannina, Arta, Grecia.

C. Introducción

Las señales eléctricas obtenidas en un EEG son el resultado incidental de la actividad eléctrica en el tejido nervioso, se producen cuando las neuronas generan potenciales eléctricos al comunicarse entre sí en el momento de recibir un estímulo externo, o cuando se desea realizar alguna función en el organismo.

La EA se trata de una enfermedad neurodegenerativa progresiva que da lugar a alteraciones cognitivas, conductuales y funcionales, así como cambios a nivel microscópico. Estos últimos se caracterizan, fundamentalmente, por la acumulación progresiva de placas seniles y anillos neurofibrilares en diversas zonas del cerebro. Existe un estado previo a la enfermedad conocido como DCL. Los primeros síntomas de la enfermedad se manifiestan a nivel de pequeños déficits en la memoria. A medida que la enfermedad avanza, estos déficits se agravan y se unen a alteraciones en el lenguaje y en el razonamiento. Conceptos como la amnesia retrógrada y la apraxia toman especial importancia. Finalmente, aparecen problemas motores y una atrofia global del cerebro que puede llevar a la incapacidad completa del enfermo

D. Objetivos

1. Objetivo general

Investigar e implementar las técnicas para la extracción de datos de un EEG para obtener información relevante que ayude a tener una relación de las señales encefalográficas y los pacientes con EA, se pretende ver un tipo de tendencia o comportamiento de la EA y de pacientes con cerebro sano para ver una comparación de los resultados y comportamiento, se hará uso de visualizaciones de PSD para ver la actividad, y de un cluster de 10 pacientes para ambos casos para ver la media que presentan las señales y PSD para ambos clusters.

2. Objetivos particulares

- Determinar las características adecuadas que se pueden extraer del EEG y PSD que permitan identificar la EA.
- Hacer un cluster y análisis estadística que permitan determinar o clasificar a un paciente sano con uno con EA.

E. Generación de EEG

1. Lóbulos del cerebro

Un lóbulo es una parte de la corteza cerebral que subdivide el cerebro según sus funciones. El cerebro humano se divide en 6 lóbulos funcionales¹ principales: lóbulo frontal, lóbulo parietal, lóbulo temporal, lóbulo occipital, lóbulo de la ínsula y lóbulo límbico. Para este estudio solo nos van a interesar los lóbulos occipital, temporal, parietal y frontal

2. Señales de EEG

El cerebro viviente produce una salida continua de pequeñas señales eléctricas. El registro de estas señales, llamado EEG, es la suma de todos los potenciales postsinápticos (cambio temporal en el potencial de membrana de la célula) de las neuronas en la corteza cerebral. Las amplitudes de estas señales son tan pequeñas que se miden en microvoltios que son millonésimas de voltios o milésimas de milivoltios. Aunque son pequeñas, las señales se pueden detectar y registrar con precisión. Los electrodos que captan estas señales están en contacto con el cuero cabelludo. Estas señales se amplifican miles de veces. Las señales amplificadas son grabadas con un electroencefalógrafo, que es un dispositivo para registrar las señales EEG.

El EEG es un registro continuo de ondas de frecuencia y amplitud variables. El número de ciclos de onda de los picos que se produce en un patrón de EEG en un período de tiempo determinado es su frecuencia. La amplitud del patrón de EEG es la energía eléctrica del patrón en términos de microvoltios.

Para obtener el electroencefalograma se requiere de la colocación de electrodos, encargados de transformar las corrientes iónicas procedentes del tejido cerebral en corrientes eléctricas en la superficie craneal. Estos electrodos se encuentran conectados a un conjunto de canales independientes, permitiendo la captación y amplificación de la diferencia de potencial entre los electrodos receptores, y dirigiendo las señales recibidas a un dispositivo de registro. Existen varios tipos de electrodos según la forma que se obtiene el registro

Las señales EEG se obtienen de forma sencilla y ofrecen mucha información de la actividad del cerebro, la cual nos sugiere que podemos ver en esta algunos trastornos mentales,

3. Visualización de un EEG

En este estudio el set de datos a usar solo se utilizarán 19 electrodos en los pacientes al momento de raelizar el eeg, los cuales fueron colocados de la siguiente manera Una vez conectados

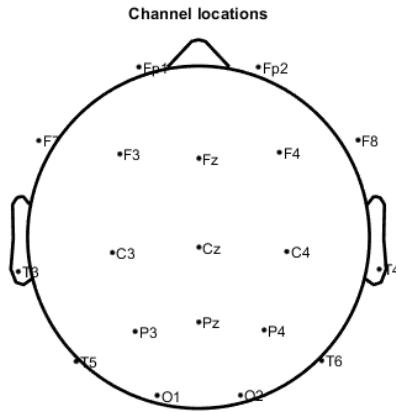


Figura 1: Ubicación de los electrodos

los electrodos en los pacientes se procede a hacer la lectura de las señales encefalográficas por medio del eeg, se van a registrar las señales individualmente por cada canal (electrodos) conectados

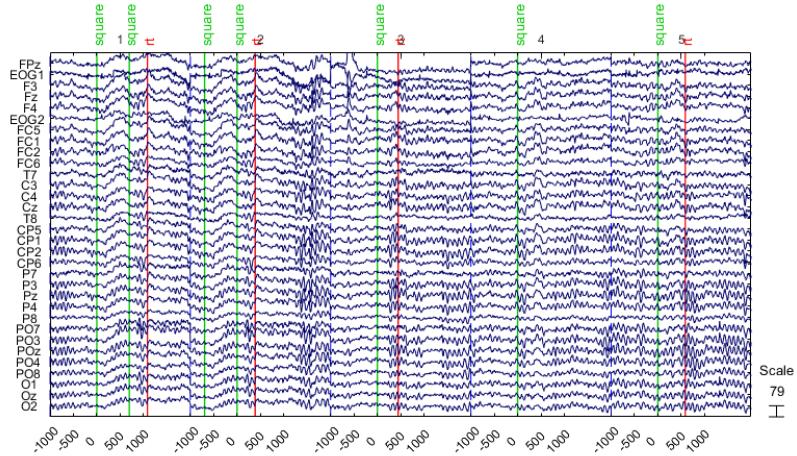


Figura 2: Señales del EEG de un paciente sano

La actividad cerebral puede variar dependiendo si el paciente al momento de medir sus señales encefalográficas esta sometido bajo un estímulo, en este caso era un sujeto de prueba que apretaba un botón bajo cierto estímulo.

Para este estudio se usara un set de datos de pacientes con EA y pacientes sanos que se encuentran en sueño inducido (eyes-closed)

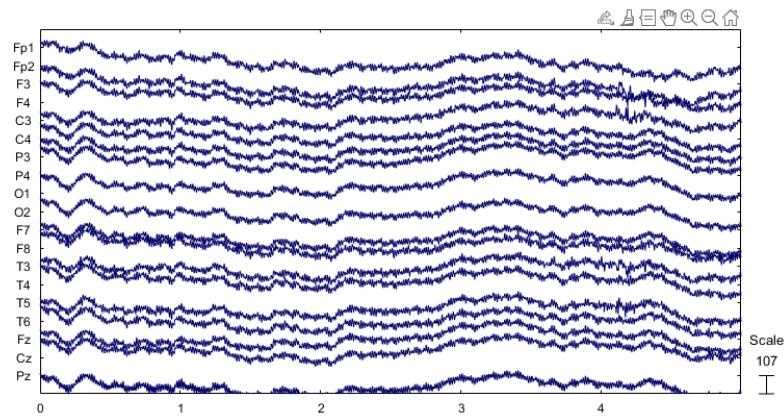


Figura 3: Señales del EEG de un paciente sano (eyes-closed)

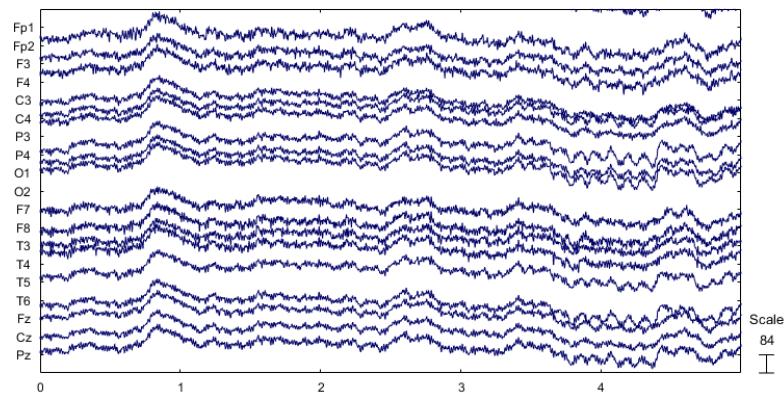


Figura 4: Señales del EEG de un paciente con EA (eyes-closed)

F. Espectro de potencia

El espectro de potencia es una función matemática que da a conocer la distribución de la potencia de dicha señal sobre las distintas frecuencias en donde está formada, esto lo usamos para visualizar de mejor manera el estado de los pacientes es mediante la actividad cerebral presentada durante el EEG, esto nos puede ayudar para la detección de diversas patologías, en este caso para la EA, se tomará la actividad cerebral de pacientes sanos y de pacientes con EA y se verá cuál es la diferencia entre cada uno, y después se comparará pacientes con EA avanzado y con EA en desarrollo para poder hacer un análisis de neurodegeneración para ver cómo se comporta y la tendencia que tiene la EA para poder hacer una detección temprana para pacientes que empiezan a desarrollar la enfermedad.

En un análisis cuantitativo de los EEG, las propiedades de los EEG medidos se cuantifican a través de ciertos parámetros obtenidos de la estimación de la PSD de muestras EEG representativas. Las muestras para las cuales se calcula la PSD se asume que son casi estacionarias. Si el EEG no es estacionario, lo cual es normal en el caso de grabaciones reales, se debería modelar como la salida de un sistema variante en el tiempo. Las estimaciones del EEG se pueden llevar a cabo con métodos no paramétricos (basados en la transformada de Fourier) o con métodos paramétricos, univariados o multivariados.

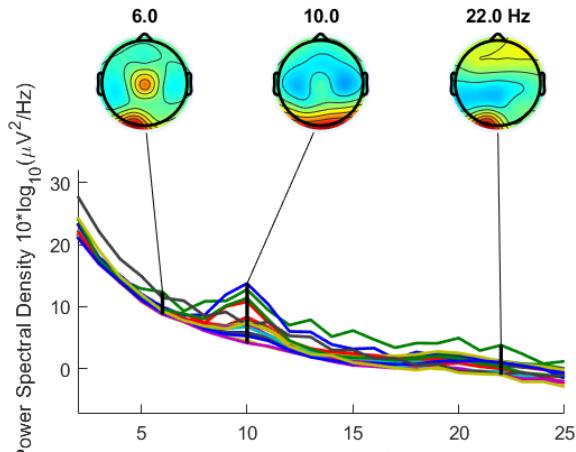


Figura 5: Paciente sano (eyes-closed)

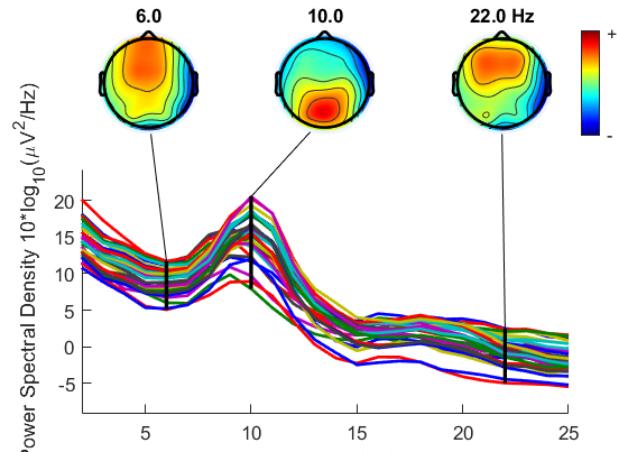


Figura 6: Paciente sano

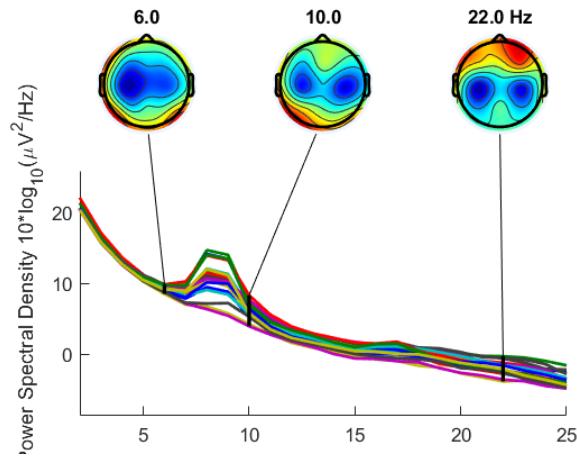


Figura 7: Paciente con EA avanzada

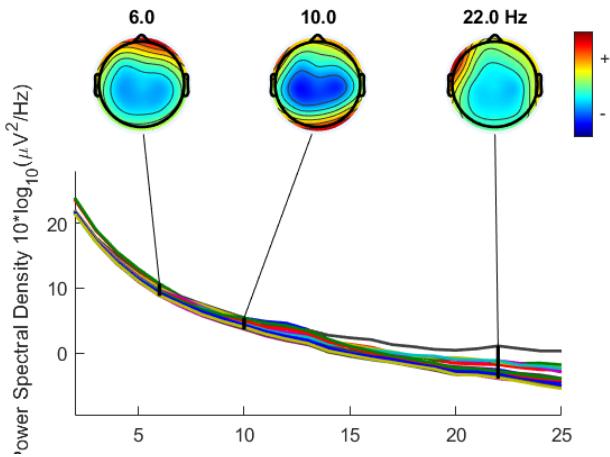


Figura 8: Paciente con EA

Esto es un PSD, donde se saca la densidad de cada uno de los 19 canales en los que se realizó el EEG, podemos apreciar resultados esperados en el espectro de potencia, podemos ver que el paciente sano presenta mayor actividad que un paciente con EA, también observamos la comparativa entre el funcionamiento del cerebro en un paciente despierto con respecto a uno dormido.

En el caso de los 2 pacientes con EA, el de la figura 7 es un paciente de 78 años con 22 MMSE, y el de la figura 8 es un paciente con 71 años con 4 MMSE.

Inspeccionando los gráficos de PSD se observa una baja actividad en los canales centrales de los pacientes con EA, y una actividad normal en todos los canales para el sano que es lo esperado, para los pacientes con EA se analizarán los canales centrales (Fz, Cz y Pz) y se comparan para ver su comportamiento, después se realizará un cluster para ver la tendencia en un scalp map y ver el PSD de la tendencia de 10 pacientes sanos, y otro cluster para pacientes con EA.

1. Canales

Para entender mejor los graficos PSD se van analizar los canales individuales de cada electrodo conectado al paciente, para ver tanto el comportamiento individual y ver cuales serían los mas importantes a analizar para ver una tendencia al momento de realizar el cluster.

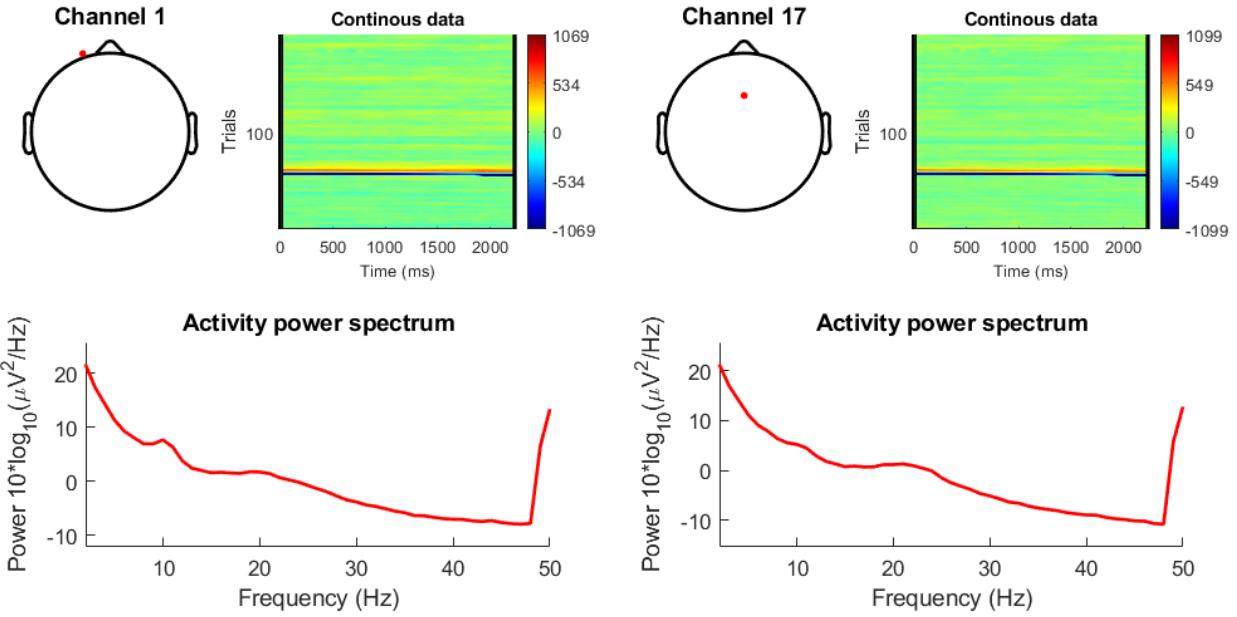


Figura 9: Canal 1 paciente sano (eyes-closed) Figura 10: Canal 17 paciente sano (eyes-closed)

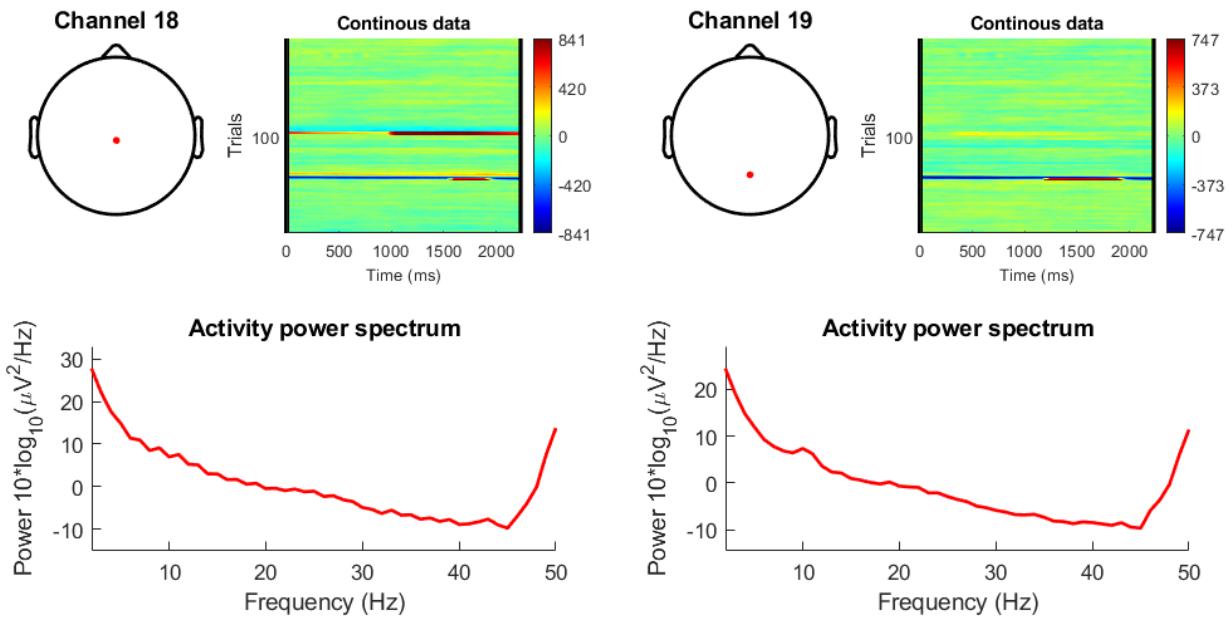


Figura 11: Canal 18 paciente sano (eyes-closed) Figura 12: Canal 19 paciente sano (eyes-closed)

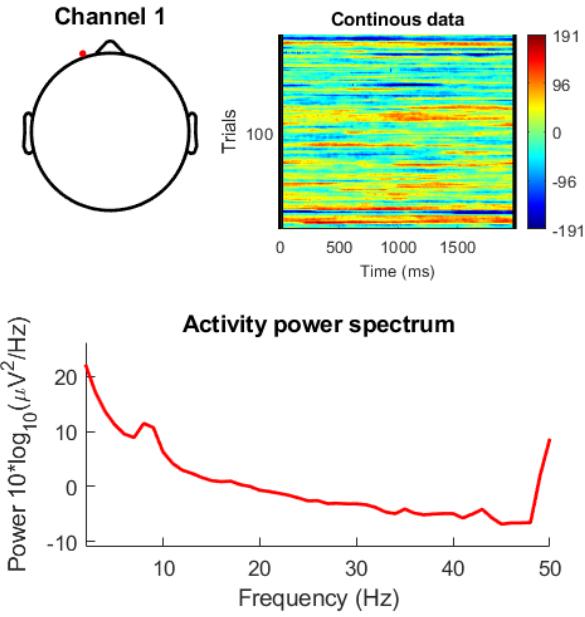


Figura 13: Canal 1 paciente EA (22 MMSE)

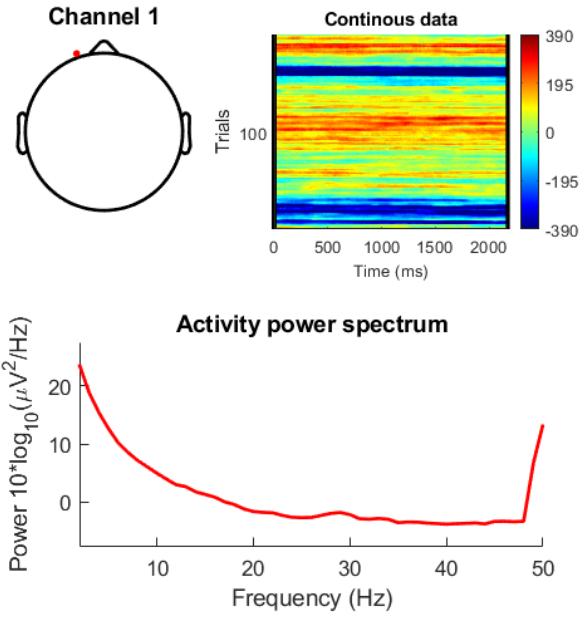


Figura 14: Canal 1 paciente EA (4 MMSE)

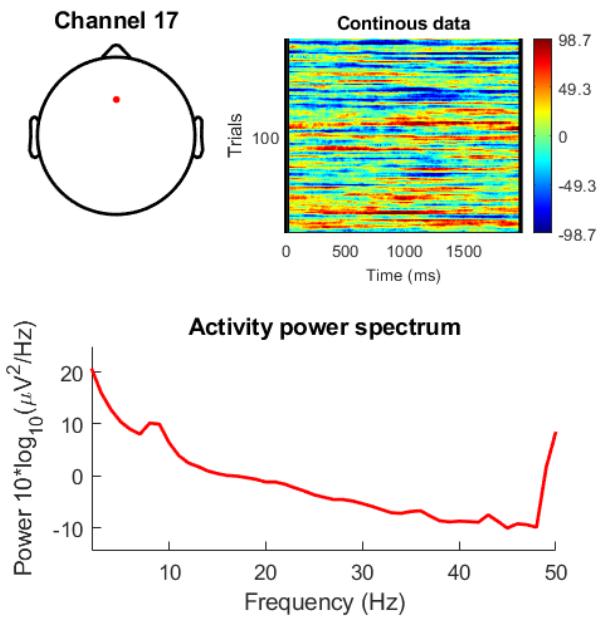


Figura 15: Canal 17 paciente EA (22 MMSE)

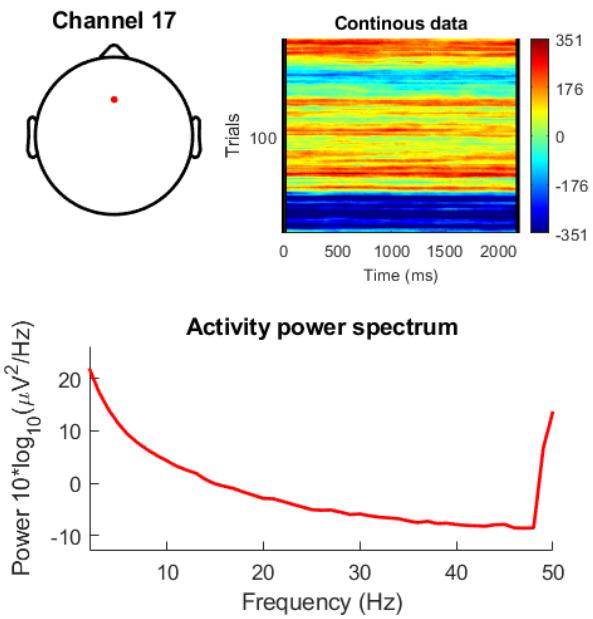


Figura 16: Canal 17 paciente EA (4 MMSE)

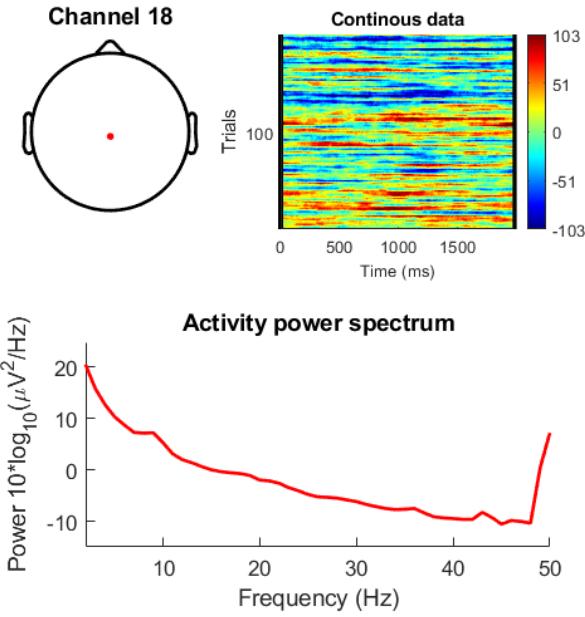


Figura 17: Canal 18 paciente EA (22 MMSE)

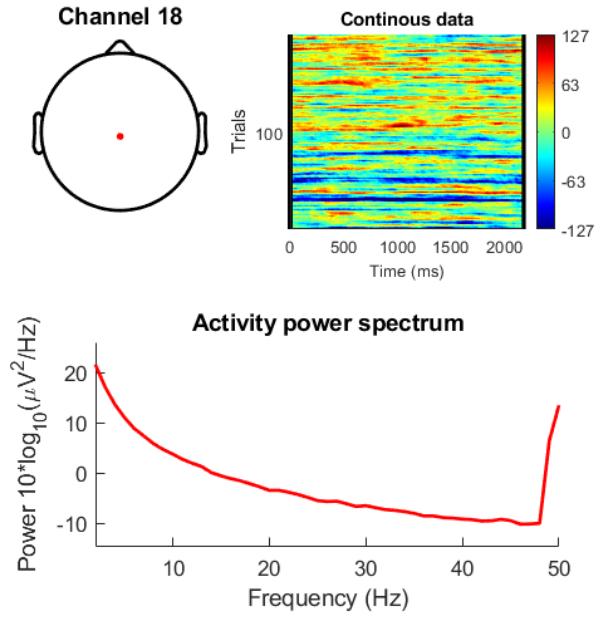


Figura 18: Canal 19 paciente EA (4 MMSE)

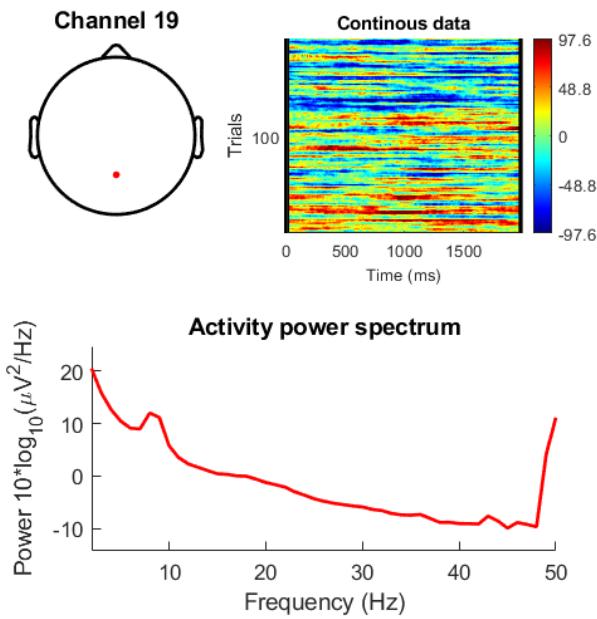


Figura 19: Canal 18 paciente EA (22 MMSE)

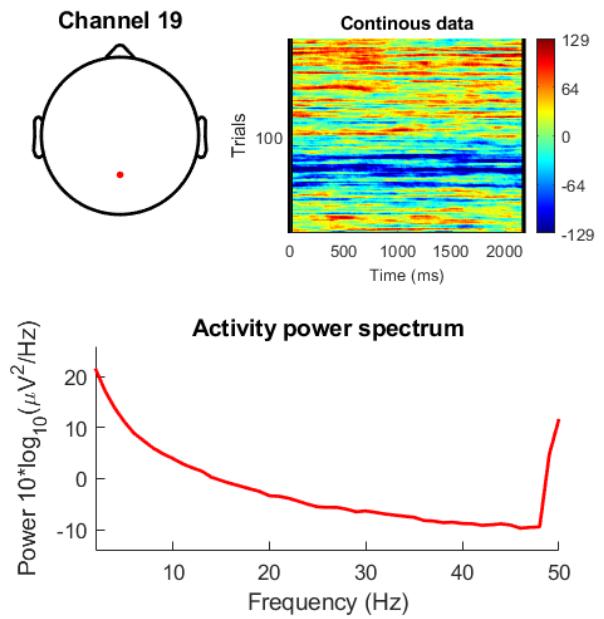


Figura 20: Canal 19 paciente EA (4 MMSE)

2. Cluster

Un cluster se encarga de agrupar objetos por similitud, en grupos o conjuntos de manera que los miembros del mismo grupo tengan características similares. Para tener una mejor resolución en los datos haremos uso de ICA

3. ICA

Se utiliza para eliminar/restar artefactos incrustados en los datos (músculos, parpadeos o movimientos oculares) sin eliminar las partes de datos afectadas, lo usamos para filtrar el ruido en nuestros datos para obtener mejores mediciones.

Para realizar una visualización de la actividad cerebral y el APS se van a tomar los datos del EEG y PSD de 10 pacientes con cerebro sano y 10 con EA, después de se van a comparar los resultados obtenidos para ver una relación y poder obtener una tendencia para ver como se diferencia el comportamiento que tiene un cerebro normal y uno con EA, y desúes poder dar una tendencia para la neurodegeneración que produce la enfermedad.

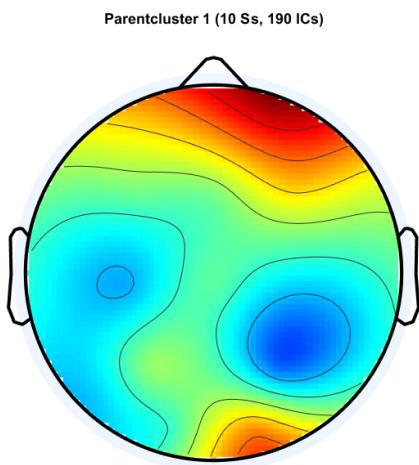


Figura 21: Cluster de EA

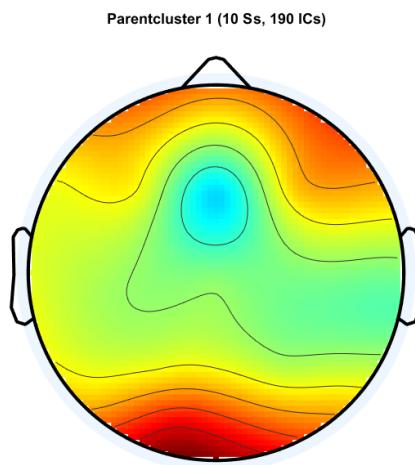


Figura 22: Cluster de cerebro sano

Esto es un resultado esperado, ya que vemos que la EA presenta una baja actividad en los canales centrales y los pacientes sanos presentaban una actividad a una frecuencia encontrada en un valor medio.

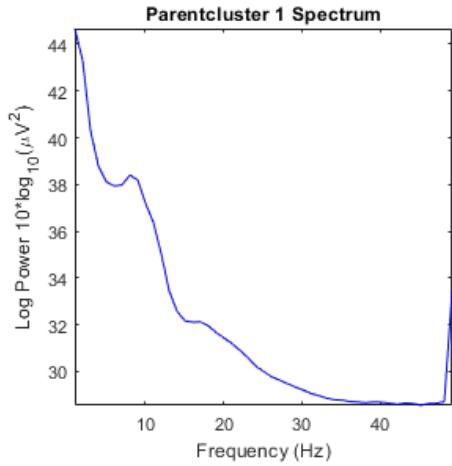


Figura 23: APS para EA

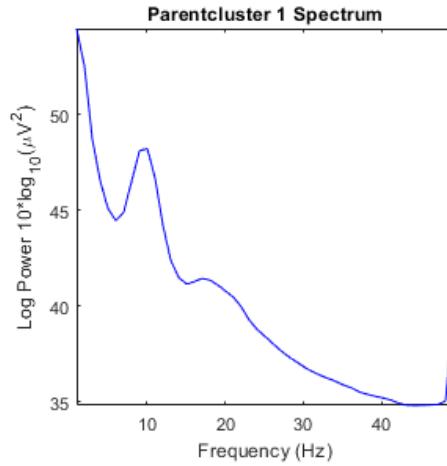


Figura 24: APS para cerebro sano

Ya se pueden observar cierto tipo de comportamiento en ambos casos, para el cerebro sano en el APS presenta un pico en actividad en 10Hz y en la EA presenta uno en 8Hz. Comparando este cluster con los datos presentados de los 2 pacientes podemos ver que el paciente de 22 MMSE ya presenta el pico en 8Hz en su gráfico de PSD y en los gráficos de los canales Fz, Cz y Pz, ya se esta viendo un comportamiento de la EA que en los PSD presentan un pico en 8Hz y en los pacientes sanos lo presentan en 10Hz, mientras que el paciente de 4 MMSE no lo presenta, solo presenta una baja actividad cerebral esto pueda dar un indicio de DCL y asi poder comparar entre las tendencias y los datos de pacientes con una EA avanzada y poder ver un comportamiento en la neurodegeneración provocado por la EA.

G. Análisis estadístico

Se describirán los métodos que obtienen las características necesarias para poder comparar los 2 grupos (EA y cerebro sano), la información necesaria que se usará como base para los métodos descritos se obtienen de las señales de EEG. Las características elegidas son entropía espectral, histogramas de distribución gaussianas y coeficiente de correlación de Pearson.

1. Entropía espectral

Uno de los problemas para la extracción de datos de EEG es que la señal de EEG es compleja, no lineal, no esática y de naturaleza aleatoria. Se consideran estacionarias dentro de intervalos cortos, es decir, cuasiestacionarios durante períodos de tiempo más largo, las características de la señal no son estacionarias. Numerosos métodos de extracción de características lineales aplican una técnica de ventana de corto tiempo a las señales de EEG

para cumplir el requisito de ser cuasiestacionarias, esta suposición se mantiene para una condición cerebral normal, pero durante las actividades mentales y físicas esta suposición no es valida. Se puede observar una señal EEG no estacionaria durante el cambio de estado de alerta y vigilia, durante el parpadeo de los ojos, entre otra estimulaciones.

La entropía es una medida de incertidumbre. En los sistemas de interfaz cerebro-computadora, la entropía puede usarse para medir el nivel de caos del sistema. Es una medida no lineal que cuantifica el grado de complejidad en una serie temporal.

Shannon definió el concepto de información de una distribución de probabilidad. En 1979, Powell y Percival introdujeron la entropía espectral basada en los picos de transformada de Fourier como una medida de regularidad. Esta definición también se extendió a la PSD del EEG y se puede calcular con la siguiente expresión:

$$H(f) = -\frac{1}{\ln(N)} \sum_{i=1}^N p_i \ln(p_i) \quad (1)$$

Donde p_i es la probabilidad para el punto i en una distribución de probabilidad, la suma de todos los p_i es igual a 1 y N es la longitud del arreglo. La entropía refleja que tan bien uno puede predecir el comportamiento de cada parte respectiva a la trayectoria desde el otro. Básicamente, una entropía más alta indica sistemas más complejos o caóticos, por lo tanto, menos predecible.

2. Coeficiente de correlación de Pearson

El coeficiente r de Pearson, también conocido como la correlación producto-momento de Pearson, se usa a menudo en los paquetes de software modernos disponibles para visualización de datos y ajuste de curvas.

Se define como la razón de la covarianza de dos variables que representan un conjunto de datos numéricos, normalizados a la raíz cuadrada de sus varianzas:

$$r = \frac{S_{xx}}{\sqrt{S_{xx}C_{yy}}} = \frac{S_{xx}}{\sigma_x \sigma_y} \quad (2)$$

3. Residuales

Los residuales la suma de los cuadrados de residuos (desviaciones predichas a partir de valores empíricos reales). Es una medida de la discrepancia entre los datos y un modelo de estimación, como una regresión lineal. Un RSS pequeño indica un ajuste estrecho del modelo a los datos. Se utiliza como criterio de optimización en la selección de parámetros y la selección de modelos.

En general, suma total de cuadrados = suma explicada de cuadrados + suma residual de cuadrados

Tenemos una relación con el coeficiente de Pearson, en el cual la línea de regresión de mínimos cuadrados está dada por:

$$y = ax + b$$

Donde $b = \bar{y}$ y $x = \frac{S_{xy}}{S_{yy}}$, por tanto la expresión queda

$$\text{RSS} = \sum_{i=1}^n (y_i - f(x_i))^2 = \sum_{i=1}^n (y_i - (ax_i + b))^2 = \sum_{i=1}^n (y_i - ax_i - \bar{y} + a\bar{x})^2 \quad (3)$$

$$= \sum_{i=1}^n (a(\bar{x} - x_i) - (\bar{y} - y_i))^2 = a^2 S_{xx} - 2aS_{xy} + S_{yy} = S_{yy} - aS_{xy} = S_{yy} \left(1 - \frac{S_{xy}^2}{S_{xx}S_{yy}} \right) \quad (4)$$

Donde $S_{yy} = \sum_{i=1}^n (\bar{y} - y_i)^2$.

Finalmente la correlación producto-momento de Pearson está dada por $r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}$ por lo tanto obtenemos:

$$\text{RSS} = S_{yy}(1 - r^2) \quad (5)$$

Ya obteniendo esto se analizaran nuestros residuales de ambos clusters y los individuales para ver que ajuste se acopla mejor a nuestros datos

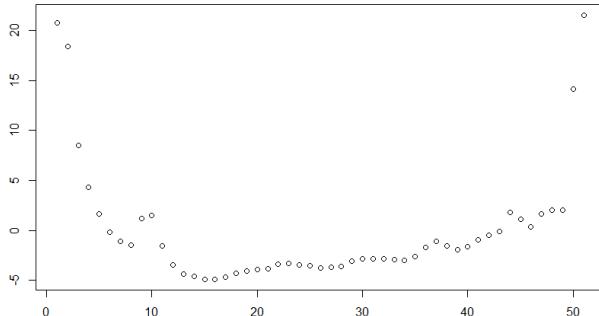


Figura 25: RSS para EA

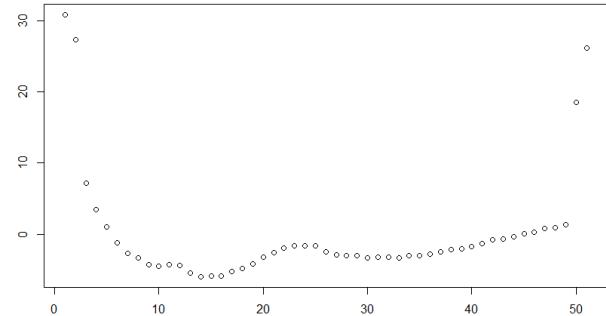


Figura 26: RSS para cerebro sano

Podemos observar un comportamiento de decaimiento exponencial en nuestros datos de PSD tanto para el cerebro sano y para el de EA, esto lo vamos utilizar para linealizar nuestros datos y facilitar nuestro análisis, ya que sera más fácil trabajar con datos lineales.

Cabe también mencionar que para estos set de datos el coeficiente de Pearson nos devuelve un $r = 0,78$ y $0,73$ para EA y cerebro sano respectivamente.

Volvemos a realizar este mismo análisis para los datos obtenidos en el cluster: Aquí se observa

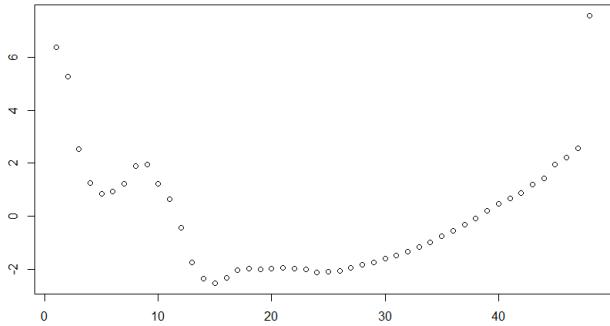


Figura 27: RSS para cluster EA

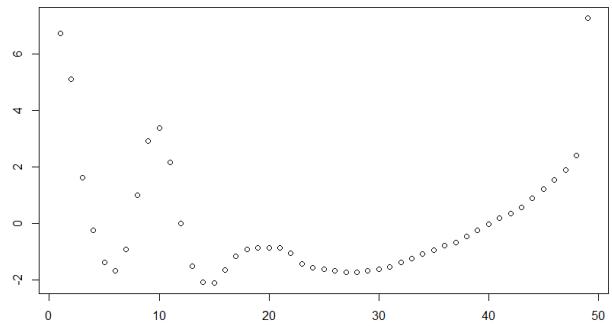


Figura 28: RSS para cluster cerebro sano

un comportamiento similar a los datos individuales, solamente que después de un decaimiento exponencial al inicio se nos presenta un pico, para EA el pico se encuentra en 8Hz y para el cerebro sano se encuentra en 10Hz, después de eso seguimos observando el mismo comportamiento de decaimiento exponencial después de ese pico, y un ligero crecimiento ya en las frecuencias mas altas.

El coeficiente de Pearson para los clusters de EA y sano no da $r = 0,85$ y $r = 0,90$ respectivamente.

4. Gráfico Q-Q

Los gráficos Q-Q comparan dos distribuciones de probabilidad mediante el trazado de sus cuantiles uno contra el otro. Un gráfico Q-Q se utiliza para comparar las formas de las distribuciones, proporcionando una vista gráfica de cómo las propiedades, como la ubicación, la escala y la asimetría, son similares o diferentes en las dos distribuciones. Una forma básica de gráfico surge cuando la distribución para la comparación es una distribución teórica. sin embargo, puede usarse la misma idea para comparar las distribuciones inferidas directamente de dos conjuntos de observaciones, donde los tamaños de las muestras sean distintos.

Un ejemplo del tipo de diferencias que pueden comprobarse es la no-normalidad de la distribución de una variable en una población. Para una muestra de tamaño n , se dibujan n puntos con los $(n + 1)$ -cuantiles de la distribución de comparación. Si la distribución de la variable es la misma que la distribución de comparación se obtendrá, aproximadamente, una línea recta, especialmente cerca de su centro.

Los gráficos Q-Q son similares a los gráficos de probabilidad. La diferencia es que en un gráfico de probabilidad, en lugar de usar el cuantil de la distribución como eje X, se usa la esperanza matemática del estadístico de k-ésimo orden de la distribución.

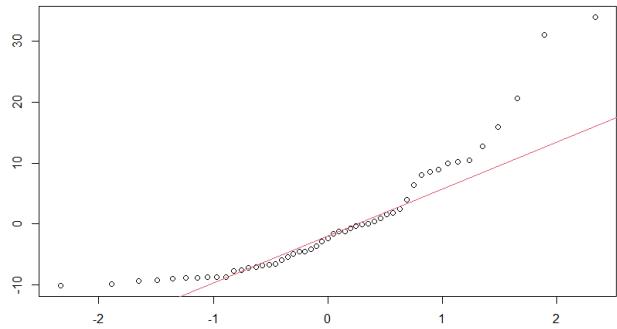


Figura 29: Q-Q para EA

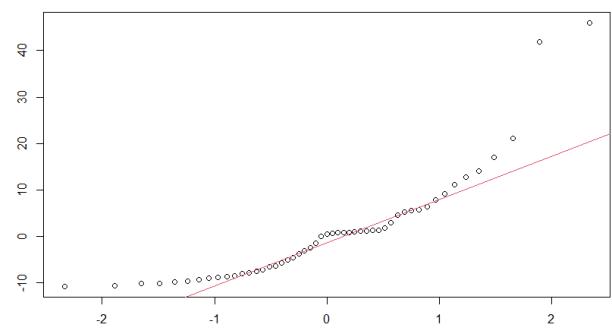


Figura 30: Q-Q para cerebro sano

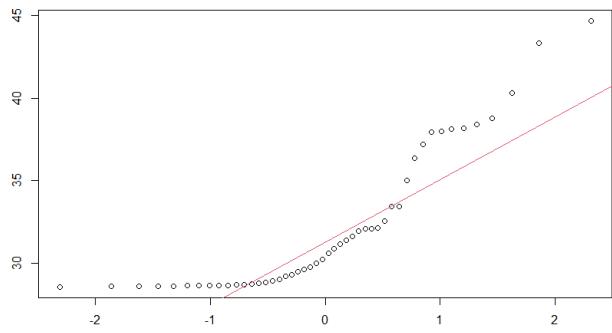


Figura 31: Q-Q para cluster EA

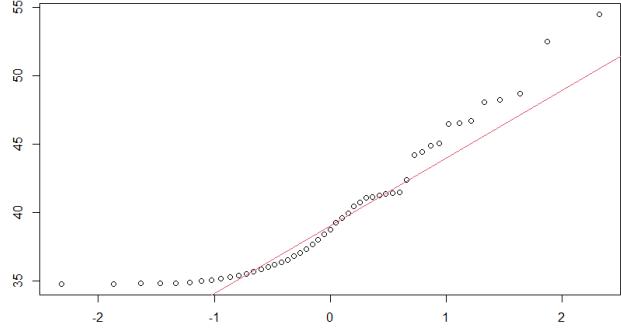


Figura 32: Q-Q para cluster cerebro sano

Observamos una linea (qqline) que pasa por el centro de los 4 Q-Q plot, esto indica un buen ajuste entre los datos.

También se puede observar una pequeña desviación al final del Q-Q plot, pero este comportamiento es esperado para la distribuciones de naturaleza exponencial.

5. Linealización del cluster

Ya observamos un comportamiento exponencial en los datos obtenidos del cluster de EA y cerebro sano, con esto linealizamos la función, del tipo:

$$y = AB^{kx}$$

$$\log_B(y) = \log_{AB^{kx}}$$

$$\log_B(y) = kx + \log_B A$$

$$v = kx + L$$

Con estos nuevos parametros linealizaremos los datos obtenidos del cluster:

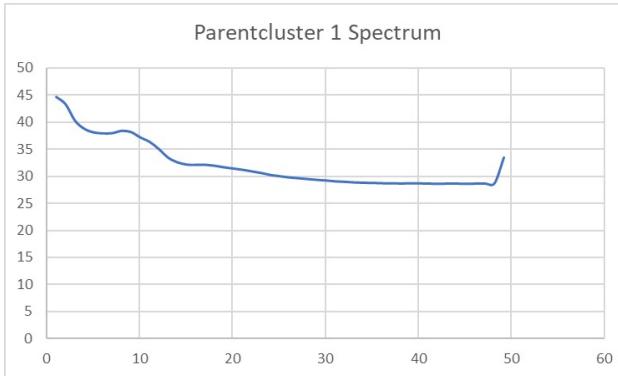


Figura 33: cluster EA

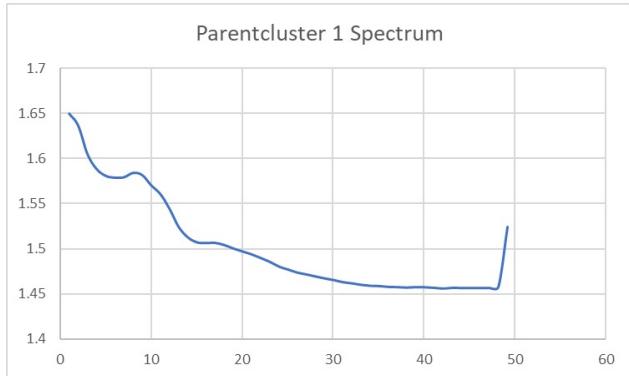


Figura 34: Linealización para cluster EA

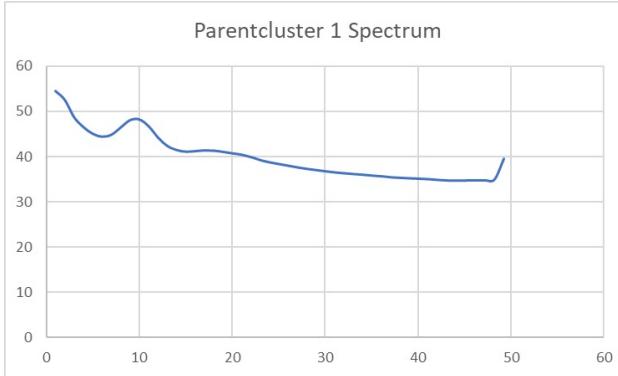


Figura 35: cluster cerebro sano

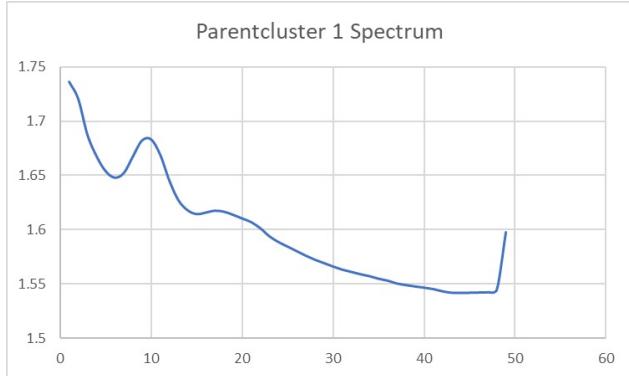


Figura 36: Linealización para cluster cerebro sano

Ya con esto se pueden revisar mejor los datos, vemos que el cerebro sano sigue presenciando el pico en frecuencia de 10Hz y EA en 8Hz, esto era el resultado esperado, que se podria encontrar una tendencia en el comportamiento, pero cabe destacar que si se quiere "tomar como patrón" el pico de 8Hz en EA vemos un problema con el PSD de los datos del paciente con 4 MMSE ya que son los datos de un paciente diagnosticado con EA pero que no presenta es pico en 8Hz como lo hace el cluster y el paciente de 22 MMSE, en el único análisis que han coincidido de momento es en el que el paciente con EA de 4 MMSE presenta una baja actividad cerebral, pero generalmente eso no es suficiente para dar diagnóstico de que se trata de EA ya que eso puede ser generado por alguna otra enfermedad, algún tipo de dalo o trauma cerebral.

Para seguir analizando la comparación del paciente de 4 MMSE y 22 MMSE y que es lo que hace que el paciente de 4 MMSE sea lo que tenga alzheimer se hara uso de la distribución gaussiana para poder ver la tendencia.

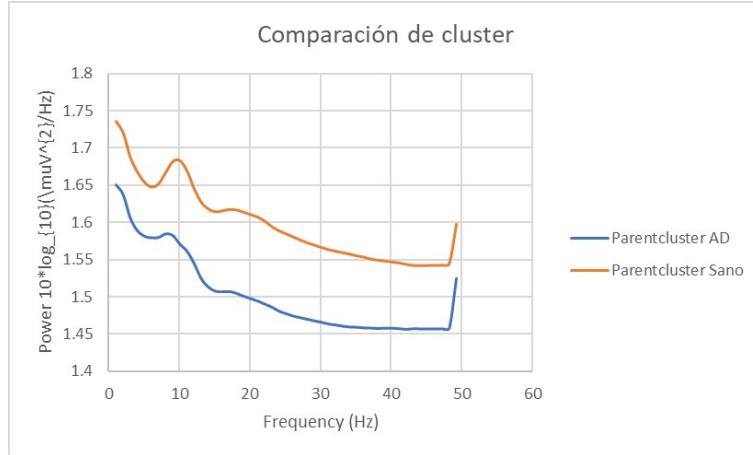


Figura 37: Linealización ambos cluster

6. Distribución Gaussiana e Histogramas

Con la distribución gaussiana o normal se pretenden ver donde se concentran la mayoría de los datos al analizar y con el histograma ver la frecuencia de observaciones dentro de los datos medidos del EEG.

Los histogramas son útiles para visualizar la forma general de la distribución de los datos, incluyendo la centralidad, dispersión y forma de la distribución. Pueden ser utilizados para identificar patrones, tendencias y características importantes en los datos, con ello se pretende dar un resultado al problema de la ausencia de la tendencia del pico en 8Hz del paciente de 4 MMSE.

En el eje vertical se representan las frecuencias, es decir, la cantidad de población o la muestra, según sea el caso, que se ubica en un determinado valor o subrango de valores de la característica que toma la característica de interés. Evidentemente, cuando este espectro de valores es infinito o muy grande, se reduce a solo una parte que muestre la tendencia o comportamiento de la población. En otras ocasiones, este espectro es extendido para mostrar el alejamiento o ubicación de la población o la muestra analizada respecto de un valor de interés.

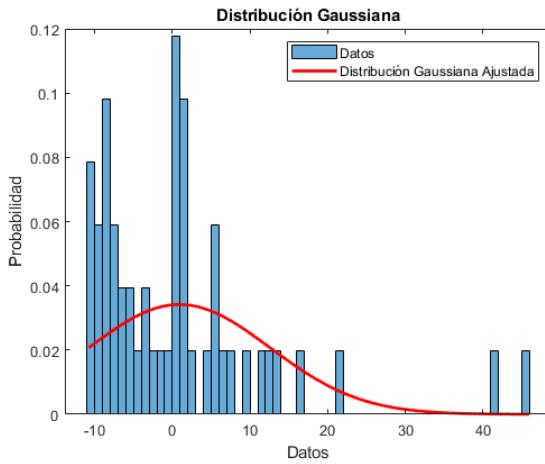


Figura 38: Histograma cerebro sano (canal 17)

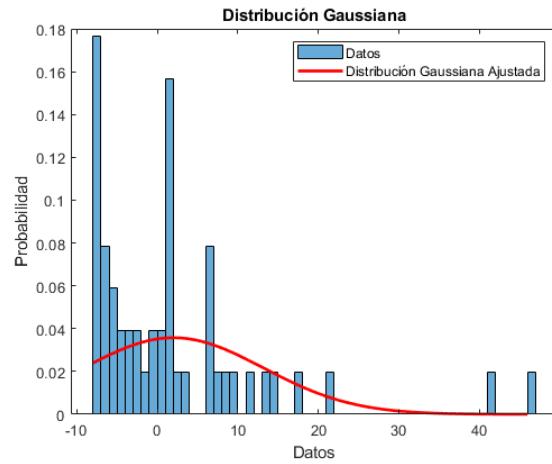


Figura 39: Histograma cerebro sano (canal 1)

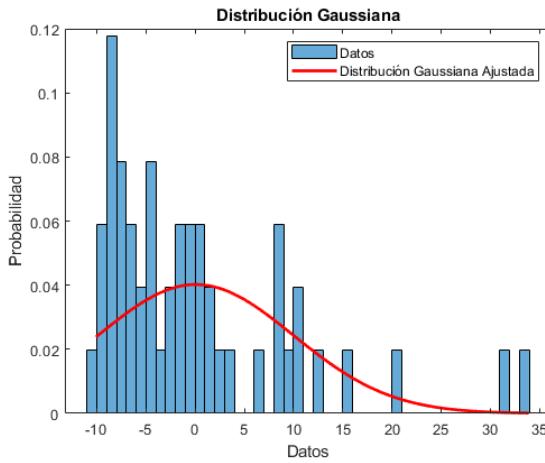


Figura 40: Histograma EA con 22 MMSE

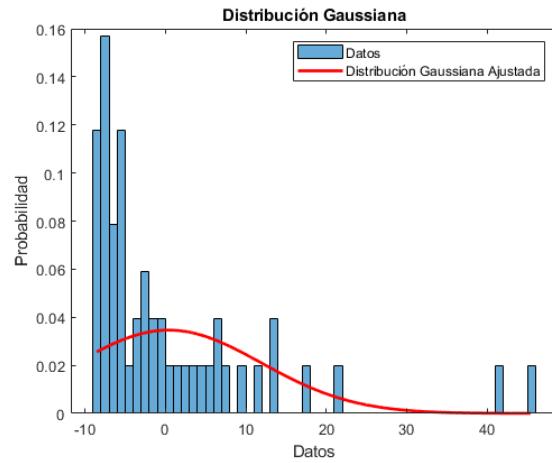


Figura 41: Histograma EA con 4 MMSE

Para el cerebro sano se usaron dos canales distintos mas que compararlo con otro paciente por que la intención es ver como se comporta un canal frontal con un canal central, ya que el central es de interes ver la diferencia de comportamiento con un paciente de EA ya que la zona central de cerebro es que mas afectada se ve por esta enfermedad.

Ya con esto se puede observar lo que se andaba buscando, como relacionar el paciente con 4 MMSE con el de 22 MMSE y el cluster de EA, con el histograma se observa que ambos ahora ya presentan una probabilidad mas alta en encontrarse en 8Hz, esto logra relacionar los datos de ambos pacientes.

H. Conclusión

El diagnóstico de EA mediante un EEG no es toda la información necesaria para poder decir si un paciente padece la enfermedad, ya que se pueden encontrar ciertos tipos de patrones en las señales, pero eso generalmente no porta la suficiente información para diferenciar una patología con otra, por ejemplo, vemos una baja actividad cerebral en los canales centrales, pero eso no fue suficiente ya que eso puede ser consecuencia de alguna otra enfermedad o algún tipo de daño o trauma.

Pero cabe destacar que pese a que el EEG no sea suficiente por si solo, se pudo llegar a una tendencia que presentaba la enfermedad con respecto a un paciente con EA avanzada (paciente con 22 MMSE) a uno con DCL (paciente con 4 MMSE), se mira en el PSD que el de 4 MMSE no presente el pico en 8Hz, pero al realizarse un estudio estadístico vemos que intrinsecamente ya se presenta en la enfermedad, el pico de 8Hz ya se hace visible en estado de mayor neurodegeneración como fue visto en el cluster.

Hacer un estudio más a fondo de la neurodegeneración hubiera sido interesante, pero eso no se puede ver tan fácilmente solo teniendo un estudio de PSD y de las señales EEG, se hubiera necesitado tener acceso a las imágenes producidas por MRI o PET de los pacientes, así mismo tener acceso a cuanta masa cerebral presentaban para hacer comparación de cuanta masa iban perdiendo a medida la enfermedad iba avanzado y tener una referencia de a que razón se iba perdiendo esa masa para intentar realizar una tendencia del proceso.

I. Referencias

- [1] Phung. D. Using Shanon entropy as eeg signal feuture for fast person identification. European symposium on Arteficial Neural Networks, Computational Inteligence and Machine Learning, Pags 413-418, 2014
- [2] Miltiadous, A., Tzimourta, K. D., Afrantou, T., Ioannidis, P., Grigoriadis, N., Tsalikakis, D. G., ... & Tzallas, A. T. (2023). A Dataset of Scalp EEG Recordings of Alzheimer's Disease, Frontotemporal Dementia and Healthy Subjects from Routine EEG. Data, 8(6), 95.
- [3] Delorme A Makeig S (2004) EEGLAB: an open-source toolbox for analysis of single-trial EEG dynamics, Journal of Neuroscience Methods 134:9-21.
- [4] Makeig S, Debener S, Onton J, Delorme A (2004) Mining event-related brain dynamics. Trends in Cognitive Science 8:204-210.
- [5] Delorme A, Palmer J, Oostenveld R, Onton J, Makeig S (2012) Independent EEG components are dipolar. PLOS One, 7(2).
- [6] Delorme, A., Sejnowski, T., Makeig, S. Improved rejection of artifacts from EEG data using high-order statistics and independent component analysis. Neuroimage. 2007; 34, 1443-1449.
- [7] Onton J, Delorme, A., Makeig, S. Frontal midline EEG dynamics during working memory. NeuroImage. 2005;27, 341-356.
- [8] Makeig S, Debener S, Onton J, Delorme A (2004) Mining event-related brain dynamics. Trends in Cognitive Science 8:204-210.
- [9] Delorme A, Mullen T, Kothe C, Akalin Acar Z, Bigdely-Shamlo N, Vankov A, Makeig S. (2011) EEGLAB, SIFT, NFT, BCILAB, and ERICA: New tools for advanced EEG processing. Computat Intelligence Neurosci 2011:130714, doi: 10.1155/2011/130714.
- [10] Pernet CR, Chauveau N, Gaspar C, Rousselet GA (2011) LIMO EEG: A toolbox for hierarchical linear modeling of electroencephalographic data. Computat Intelligence Neurosci 2011:831409, doi: 10.1155/2011/831409.
- [11] Abásolo D. Analysis of EEG background activity in alzheimer´s disease patients with lempel complexity and central tendency measure. Medical engineering and Physics 28, págs. 315-322, 2006.
- [12] Archdeacon, Thomas J. (1994). Correlation and regression analysis : a historian's guide. University of Wisconsin Press. pag. 161-162. ISBN 0-299-13650-7.
- [13] Cleveland, W.S. (1994) The Elements of Graphing Data, Hobart Press ISBN 0-9634884-1-4

[14] Andreas Miltiadous and Katerina D. Tzimourta and Theodora Afrantou and Panagiotis Ioannidis and Nikolaos Grigoriadis and Dimitrios G. Tsalikakis and Pantelis Angelidis and Markos G. Tsipouras and Evripidis Glavas and Nikolaos Giannakeas and Alexandros T. Tzallas (2023). A dataset of EEG recordings from: Alzheimer's disease, Frontotemporal dementia and Healthy subjects. OpenNeuro. [Dataset] doi: doi:10.18112/openneuro.ds004504.v1.0.6